Cierre tecnico del pipeline de imputacion para PSCompPars

Proyecto `planetas`

Artefactos verificados: `reports/imputation/`

Resumen

Este documento describe, en forma reproducible y matematica, el pipeline de imputacion ejecutado sobre `PSCompPars_2026.04.25_17.36.36.csv`. El objetivo no fue inventar observaciones astronomicas, sino producir matrices completas para analisis exploratorio, Mapper/TDA y sensibilidad estadistica, preservando la trazabilidad entre valores observados, valores derivados fisicamente y valores imputados. El metodo visualizado en el reporte final es `iterative`. El HTML final declara `METODO VISUALIZADO = iterative`; los 17 PDFs individuales estan exportados en `reports/imputation/outputs/figures_pdf`; y las tablas principales en CSV/JSON estan exportadas en `reports/imputation/outputs/tables`.

Índice

1. Resumen ejecutivo **3**

2. Objetivo estadistico y advertencia epistemica **3**

3. Entrada, salida y configuracion **4**

4. Paso 1: seleccion de variables **4**

5. Paso 2: derivacion fisica antes de imputar **5**
- 5.1. Densidad planetaria 5
- 5.2. Semieje mayor por ley de Kepler 5

6. Paso 3: auditoria de faltantes **5**

7. Paso 4: transformacion logaritmica **6**

8. Paso 5: escalado robusto **6**

9. Paso 6: imputadores comparados **7**
- 9.1. Baseline de mediana 7
- 9.2. KNN 7
- 9.3. IterativeImputer 7

10. Paso 7: inversion de escala **7**

11. Paso 8: trazabilidad de fuentes **8**

12. Paso 9: validacion enmascarada **8**
12.1. Metricas de validacion para `iterative` . . . 9

13. Paso 10: seleccion del metodo visualizado **9**

14. Paso 11: cobertura Mapper **10**

15. Interpretacion de los PDFs generados **10**
15.1. `01_missingness_before_after.pdf` . . . 11
15.2. `02_value_source_composition.pdf` . . . 12
15.3. `03_mapper_coverage.pdf` . . . 13
15.4. `04_masked_validation_mae_by_feature.pdf` . . . 14
15.5. `05_masked_validation_spearman_heatmap.pdf` . . . 15
15.6. `06_method_comparison.pdf` . . . 16
15.7. PDFs `07`–`13`: distribuciones univariadas . . . 18
15.8. PDFs `14`–`17`: scatter checks bivariados . . . 20

16. Lectura de tablas exportadas **23**
16.1. `imputation_method_comparison` . . . 24
16.2. `imputation_validation_metrics` . . . 24
16.3. `imputation_value_source_composition` . . . 24
16.4. `imputation_missingness_summary` . . . 24
16.5. `mapper_coverage_summary` . . . 24

17. Implicaciones para Mapper/TDA **25**

18. Criterios de aceptacion cumplidos **25**

19. Advertencias no bloqueantes **25**

20. Conclusiones **26**

A. Rutas de artefactos **26**

B. Inventario de PDFs **26**

1. Resumen ejecutivo

El pipeline se ejecuto en modo comparativo:

$$\texttt{-method compare -visualized-method iterative}.$$

Esto significa que se estimaron tres familias de imputacion,

$$\mathcal{M} = \{\text{median}, \text{knn}, \text{iterative}\},$$

pero el reporte principal, los plots finales dependientes del metodo y las tablas exportadas en `reports/imputation/outputs` se construyeron con

$$m^\star = \text{iterative}.$$

Los conteos globales reportados son:

$$n = 6273, \qquad p = 7, \qquad N_{\text{imputadas}} = 3978, \qquad N_{\text{derivadas}} = 6619.$$

Las siete variables Mapper principales fueron:

$$\mathbf{x}_i = \big(\texttt{pl_rade}, \texttt{pl_bmasse}, \texttt{pl_dens}, \texttt{pl_orbper}, \texttt{pl_orbsmax}, \texttt{pl_insol}, \texttt{pl_eqt}\big)_i.$$

Para el archivo final en unidades fisicas, `PSCompPars_imputed_iterative.csv`, no quedaron valores NA, $+\infty$ ni $-\infty$ en estas siete variables. Ademas, las seis variables positivas que entran a escala logaritmica son estrictamente positivas:

$$\texttt{pl_rade}, \texttt{pl_bmasse}, \texttt{pl_dens}, \texttt{pl_orbper}, \texttt{pl_orbsmax}, \texttt{pl_insol} > 0.$$

El archivo `mapper_features_imputed_iterative.csv` esta en espacio transformado/escalado; por eso puede contener valores negativos, pero no contiene NA ni infinitos.

2. Objetivo estadistico y advertencia epistemica

Sea $X \in \mathbb{R}^{n\times p}$ la matriz de variables numericas seleccionadas, con patron de disponibilidad $R \in \{0,1\}^{n\times p}$:

$$R_{ij} = \begin{cases} 1, & X_{ij} \text{ disponible antes de imputar,} \\ 0, & X_{ij} \text{ faltante antes de imputar.} \end{cases}$$

La imputacion produce una matriz completa $\widehat{X}$, pero la igualdad

$$\widehat{X}_{ij} = X_{ij}$$

solo tiene interpretacion observacional cuando el valor original era medido o publicado en el CSV. Para los faltantes, $\widehat{X}_{ij}$ es una reconstruccion modelada. Por tanto:

$$\widehat{X} = X_{\text{observado}} \cup X_{\text{derivado}} \cup X_{\text{imputado}},$$

no una tabla de observaciones astronomicas independientes.

La distincion central del reporte es:

$$\text{fuente}(x_{ij}) \in \{\text{observed}, \text{derived_density}, \text{derived_kepler}, \text{imputed_median}, \text{imputed_knn}, \text{imputed_iterative}, \text{exc}$$

Estas etiquetas se resumen en categorias:

$$\text{categoria}(x_{ij}) \in \{\text{observed}, \text{physically_derived}, \text{imputed}, \text{excluded_too_missing}, \text{missing}\}.$$

Asi, la topologia inferida por Mapper debe entenderse como una propiedad del espacio completado bajo un protocolo de reconstruccion, no como una propiedad directa e incondicional del catalogo observado.

3. Entrada, salida y configuracion

La configuracion final del pipeline fue:

- CSV fuente: `PSCompPars_2026.04.25_17.36.36.csv`.
- Metodo ejecutado: `compare`.
- Metodo visualizado: `iterative`.
- Vecinos para KNN: $k = 15$.
- Pesos KNN: `distance`.
- Umbral de exclusion por faltantes: 60 %.
- Fraccion de mascara para validacion: 0,15.
- Semilla aleatoria: 42.
- Variables incluidas: las siete variables Mapper principales.
- Variables excluidas: ninguna dentro de esas siete.

El comando reproducible documentado es:

```
python .\src\impute_exodata.py --csv .\data\PSCompPars_2026.04.25_17.36.36.csv
  --reports-dir .\reports\imputation
  --outputs-dir .\reports\imputation\outputs
  --method compare
  --visualized-method iterative
  --n-neighbors 15
  --weights distance
  --max-missing-pct 60
  --validation-mask-frac 0.15
  --random-state 42
```

4. Paso 1: seleccion de variables

El conjunto de variables objetivo fue:

$$\mathcal{F} = \{\texttt{pl_rade}, \texttt{pl_bmasse}, \texttt{pl_dens}, \texttt{pl_orbper}, \texttt{pl_orbsmax}, \texttt{pl_insol}, \texttt{pl_eqt}\}.$$

El criterio practico fue conservar variables fisicas relevantes para dos subespacios Mapper:

$$\mathcal{F}_{\text{phys}} = \{\texttt{pl_rade}, \texttt{pl_bmasse}, \texttt{pl_dens}\},$$

$$\mathcal{F}_{\text{orb}} = \{\texttt{pl_orbper}, \texttt{pl_orbsmax}, \texttt{pl_insol}, \texttt{pl_eqt}\}.$$

El espacio conjunto fue:

$$\mathcal{F}_{\text{joint}} = \mathcal{F}_{\text{phys}} \cup \mathcal{F}_{\text{orb}}.$$

5. Paso 2: derivacion fisica antes de imputar

Antes de aplicar imputacion estadistica, el pipeline deriva propiedades con formula fisica clara. Esto reduce imputacion innecesaria y hace explicita la diferencia entre una magnitud observada y una magnitud calculada.

5.1. Densidad planetaria

La densidad ρ_p se reconstruyo desde masa y radio:

$$\rho_p = \rho_\oplus \frac{M_p/M_\oplus}{(R_p/R_\oplus)^3}, \qquad \rho_\oplus = 5{,}514\ \mathrm{g\,cm^{-3}}.$$

En nombres de columnas:

$$\texttt{pl_dens} = 5{,}514\,\frac{\texttt{pl_bmasse}}{\texttt{pl_rade}^3}.$$

El CSV fuente no traia observaciones originales de `pl_dens`:

$$N_{\text{observado}}(\texttt{pl_dens}) = 0.$$

Despues de la derivacion:

$$N_{\text{derived_density}}(\texttt{pl_dens}) = 6199, \qquad N_{\text{faltante}}(\texttt{pl_dens}) = 74.$$

Por eso `pl_dens` debe leerse como magnitud fisicamente derivada cuando viene de masa y radio, no como observacion independiente.

5.2. Semieje mayor por ley de Kepler

Cuando `pl_orbsmax` faltaba pero habia masa estelar y periodo orbital, se aplico:

$$a = \left[M_\star \left(\frac{P}{365{,}25} \right)^2 \right]^{1/3},$$

donde a queda en AU si $M_\star$ esta en masas solares y P en dias. En nombres de columnas:

$$\texttt{pl_orbsmax} = \left(\texttt{st_mass} \left(\frac{\texttt{pl_orbper}}{365{,}25} \right)^2 \right)^{1/3}.$$

Los conteos fueron:

$$N_{\text{observado}}(\texttt{pl_orbsmax}) = 5845, \qquad N_{\text{derived_kepler}}(\texttt{pl_orbsmax}) = 420, \qquad N_{\text{faltante despues}} = 8.$$

6. Paso 3: auditoria de faltantes

La tabla de missingness antes y despues de derivacion fisica fue:

Feature	Raw missing	Raw %	Missing post-fisica	Post-fisica %
`pl_bmasse`	31	0.4942	31	0.4942
`pl_dens`	6273	100.0000	74	1.1797
`pl_eqt`	1600	25.5061	1600	25.5061
`pl_insol`	1876	29.9059	1876	29.9059
`pl_orbper`	339	5.4041	339	5.4041
`pl_orbsmax`	428	6.8229	8	0.1275
`pl_rade`	50	0.7971	50	0.7971

La derivacion fisica tuvo dos efectos fuertes:

$$\texttt{pl_dens} : 100\,\%\ \text{faltante} \longrightarrow 1{,}1797\,\%\ \text{faltante},$$

$$\texttt{pl_orbsmax} : 6{,}8229\,\%\ \text{faltante} \longrightarrow 0{,}1275\,\%\ \text{faltante}.$$

7. Paso 4: transformacion logaritmica

Para variables positivas con colas largas se aplico:

$$z_{ij} = \log_{10}(x_{ij}).$$

El conjunto transformado fue:

$$\mathcal{L} = \{\texttt{pl_rade}, \texttt{pl_bmasse}, \texttt{pl_dens}, \texttt{pl_orbper}, \texttt{pl_orbsmax}, \texttt{pl_insol}\}.$$

No se aplico logaritmo a `pl_eqt`. La auditoria confirmo:

$$N_{\leq 0,\ \text{forzado a missing}} = 0$$

para todas las variables transformadas. Esto es importante porque evita que $\log_{10}(x)$ introduzca $-\infty$, $+\infty$ o valores indefinidos.

La matriz transformada puede escribirse como:

$$T_{ij} = \begin{cases} \log_{10}(X_{ij}), & j \in \mathcal{L},\ X_{ij} > 0, \\ X_{ij}, & j \notin \mathcal{L}. \end{cases}$$

8. Paso 5: escalado robusto

Despues del logaritmo se aplico `RobustScaler`. Para cada columna j:

$$S_{ij} = \frac{T_{ij} - \text{median}(T_{\cdot j})}{\text{IQR}(T_{\cdot j})},$$

donde

$$\text{IQR}(T_{\cdot j}) = Q_{0,75}(T_{\cdot j}) - Q_{0,25}(T_{\cdot j}).$$

Esto estabiliza variables con rangos muy distintos. Por ejemplo, `pl_orbper`, `pl_insol` y `pl_bmasse` tienen colas largas; sin escala robusta, las distancias de KNN o las regresiones iterativas quedarian dominadas por magnitudes con varianza extrema.

9. Paso 6: imputadores comparados

Sobre la matriz escalada S se evaluaron tres imputadores.

9.1. Baseline de mediana

Para cada columna j, el imputador de mediana usa:

$$\widehat{S}_{ij} = \begin{cases} S_{ij}, & R_{ij} = 1, \\ \widetilde{S}_{\cdot j}, & R_{ij} = 0, \end{cases}$$

donde $\widetilde{S}_{\cdot j}$ es la mediana observada de la columna j. Este modelo es robusto pero ignora relaciones entre variables:

$$\widehat{S}_{ij}^{\text{median}} \perp S_{i,-j}.$$

9.2. KNN

El KNN usa vecinos cercanos en el espacio de variables disponibles. Con $k = 15$ y pesos por distancia:

$$\widehat{S}_{ij}^{\text{KNN}} = \frac{\sum_{\ell \in \mathcal{N}_k(i,j)} w_{i\ell} S_{\ell j}}{\sum_{\ell \in \mathcal{N}_k(i,j)} w_{i\ell}}, \qquad w_{i\ell} \propto \frac{1}{d(i,\ell)}.$$

Aqui $d(i,\ell)$ se calcula con las columnas simultaneamente disponibles para los registros i y ℓ. KNN es atractivo para Mapper porque preserva una nocion local de vecindad, aunque puede ser sensible al patron de faltantes y a densidades locales desiguales.

9.3. IterativeImputer

El metodo `iterative` usa `IterativeImputer` con estrategia inicial de mediana, 20 iteraciones maximas, `sample_posterior=False` y semilla 42. Conceptualmente, para cada columna j con faltantes se ajusta un modelo condicional:

$$S_{\cdot j} = f_j(S_{\cdot,-j}) + \varepsilon_j,$$

y se actualizan sucesivamente las columnas faltantes:

$$\widehat{S}_{ij}^{(t+1)} = f_j^{(t)}\left(\widehat{S}_{i,-j}^{(t)}\right).$$

La ventaja es que explota dependencias multivariadas globales. La precaucion es que puede imponer relaciones suaves que no necesariamente preservan toda la geometria local del catalogo observado. Por eso el reporte mantiene la advertencia topologica: Mapper debe compararse contra casos completos, KNN, mediana, bootstrap y variaciones de parametros.

10. Paso 7: inversion de escala

Una vez imputada la matriz escalada $\widehat{S}$, se invierte el escalado:

$$\widehat{T}_{ij} = \widehat{S}_{ij} \cdot \text{IQR}(T_{\cdot j}) + \text{median}(T_{\cdot j}).$$

Luego se invierte el logaritmo para $j \in \mathcal{L}$:

$$\widehat{X}_{ij} = 10^{\widehat{T}_{ij}}.$$

Para `pl_eqt`, que no fue log-transformada:

$$\widehat{X}_{ij} = \widehat{T}_{ij}.$$

11. Paso 8: trazabilidad de fuentes

El resultado no solo contiene valores; contiene banderas de procedencia. Para cada feature j se generan columnas:

`<j>_was_missing`, `<j>_was_observed`, `<j>_was_physically_derived`, `<j>_was_imputed`, `<j>_source`.

La composicion final para el metodo `iterative` fue:

Feature	Observed	Phys. derived	Imputed	Derived density	Derived Kepler
`pl_rade`	6223	0	50	0	0
`pl_bmasse`	6242	0	31	0	0
`pl_dens`	0	6199	74	6199	0
`pl_orbper`	5934	0	339	0	0
`pl_orbsmax`	5845	420	8	0	420
`pl_insol`	4397	0	1876	0	0
`pl_eqt`	4673	0	1600	0	0

El caso critico es `pl_dens`. Su composicion:

$$(N_{\text{observed}}, N_{\text{phys}}, N_{\text{imputed}}) = (0, 6199, 74).$$

Por tanto, cualquier lectura de densidad debe declarar explicitamente si esta hablando de densidad derivada por formula o de densidad imputada despues de no poder aplicar la formula.

12. Paso 9: validacion enmascarada

Para evaluar reconstruccion, se oculto una fraccion $q = 0{,}15$ de valores disponibles. Sea Ω_j el conjunto de indices validables de la columna j. La mascara aleatoria selecciona:

$$\Omega_j^{\text{mask}} \subset \Omega_j, \qquad |\Omega_j^{\text{mask}}| \approx q|\Omega_j|.$$

Se reemplazan temporalmente por NA, se imputa y se compara:

$$e_{ij}^{(m)} = \widehat{x}_{ij}^{(m)} - x_{ij}, \qquad i \in \Omega_j^{\text{mask}}.$$

Las metricas usadas fueron:

$$\text{MAE}_j^{(m)} = \frac{1}{|\Omega_j^{\text{mask}}|} \sum_{i \in \Omega_j^{\text{mask}}} \left| \widehat{x}_{ij}^{(m)} - x_{ij} \right|,$$

$$\text{RMSE}_j^{(m)} = \sqrt{\frac{1}{|\Omega_j^{\text{mask}}|} \sum_{i \in \Omega_j^{\text{mask}}} \left(\widehat{x}_{ij}^{(m)} - x_{ij} \right)^2},$$

$$\text{MedAE}_j^{(m)} = \text{median}_{i \in \Omega_j^{\text{mask}}} \left| \widehat{x}_{ij}^{(m)} - x_{ij} \right|,$$

$$\mathrm{MAPE}_j^{(m)} = 100 \frac{1}{|\Omega_j^{\mathrm{mask}}|} \sum_{i \in \Omega_j^{\mathrm{mask}}} \left| \frac{\widehat{x}_{ij}^{(m)} - x_{ij}}{x_{ij}} \right|.$$

Para variables positivas tambien se reporto error logaritmico:

$$\mathrm{logMAE}_j^{(m)} = \frac{1}{|\Omega_j^{\mathrm{mask}}|} \sum_i \left| \log_{10} \widehat{x}_{ij}^{(m)} - \log_{10} x_{ij} \right|.$$

El reporte evita afirmar que todos los targets de validacion eran observaciones originales. En cambio registra:

$$\texttt{validation_basis} \in \{\text{observed}, \text{physically_derived}, \text{observed_and_physically_derived}\}.$$

Esto corrige una ambiguedad importante: para `pl_dens`, la validacion se hizo contra valores derivados fisicamente, no contra mediciones originales.

12.1. Metricas de validacion para `iterative`

Feature	Basis	n	MAE	RMSE	MAPE
`pl_rade`	observed	933	0.8499	2.6550	13.1821
`pl_bmasse`	observed	936	100.1072	546.3365	70.7389
`pl_dens`	physically derived	930	0.8344	7.3158	34.6446
`pl_orbper`	observed	890	7166.4684	167836.5141	33.1882
`pl_orbsmax`	mixed	940	3.3586	56.7595	24.6082
`pl_insol`	observed	660	249.6873	1483.3967	116.0500
`pl_eqt`	observed	701	162.9790	271.9118	21.2377

Para `pl_dens`, la comparacion entre metodos fue:

Metodo	MAE	RMSE	MAPE
`median`	9.6534	148.8953	145.8616
`knn`	8.7530	148.9590	61.4290
`iterative`	0.8344	7.3158	34.6446

Esto explica por que `iterative` fue seleccionado como metodo visualizado: reduce fuertemente el error en una variable fisica central, sin borrar la advertencia de que `pl_dens` es derivada principalmente desde masa y radio.

13. Paso 10: seleccion del metodo visualizado

La tabla de comparacion resume ranks promedio por error:

Metodo	Mean MAE rank	Mean RMSE rank	Features completas
`median`	2.8571	2.5714	7
`knn`	2.1429	2.1429	7
`iterative`	1.0000	1.2857	7

Si $r_{\mathrm{MAE}}(m, j)$ es el rank del metodo m en la columna j, entonces:

$$\bar{r}_{\mathrm{MAE}}(m) = \frac{1}{p} \sum_{j=1}^{p} r_{\mathrm{MAE}}(m, j).$$

El metodo visualizado es:

$$m^{\star} = \arg\min_{m \in \mathcal{M}} \bar{r}_{\mathrm{MAE}}(m) = \text{iterative}.$$

El rank RMSE tambien favorecio a `iterative`.

14. Paso 11: cobertura Mapper

La cobertura antes/despues para los espacios Mapper fue:

Grupo	Features	Complete rows before	Before %	After %
`MAPPER_PHYS_FEATURES`	3	6199	98.8203	100.0
`MAPPER_ORB_FEATURES`	4	4312	68.7390	100.0
`MAPPER_JOINT_FEATURES`	7	4282	68.2608	100.0
`JOINT + ORB optional`	8	3959	63.1117	0.0

El resultado clave es:

$$N_{\mathrm{complete}}(\mathcal{F}_{\mathrm{joint}}) : 4282 \longrightarrow 6273.$$

Es decir, el espacio conjunto de siete variables pasa de 68,2608 % de filas completas a 100 %. La opcion con `pl_orbeccen` no queda cubierta porque la variable opcional esta excluida/faltante en esta ejecucion.

15. Interpretacion de los PDFs generados

Todos los PDFs listados existen y tienen tamano mayor que cero. Las figuras se exportaron desde el metodo visualizado `iterative` cuando dependen de valores imputados finales. A continuacion se describe como leer cada una.

15.1. 01_missingness_before_after.pdf

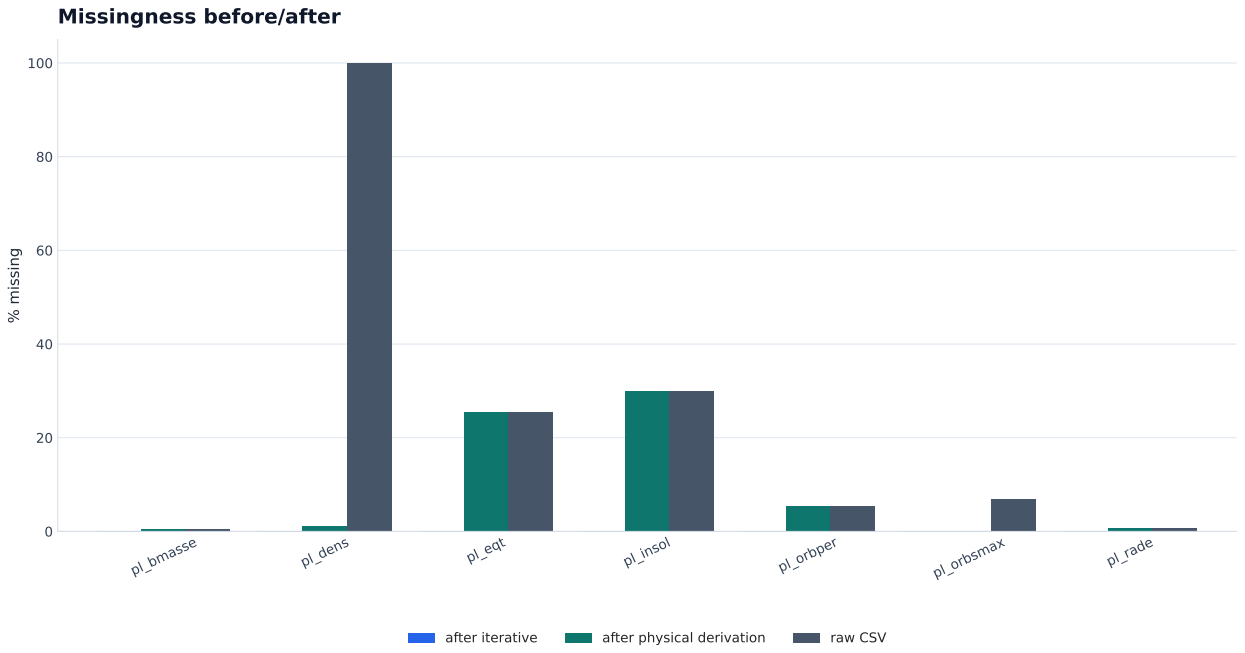

Figura 1: Missingness antes del CSV, despues de derivacion fisica y despues de imputacion `iterative`.

Esta figura compara tres etapas:

$$\text{raw CSV} \rightarrow \text{after physical derivation} \rightarrow \text{after iterative imputation.}$$

La lectura principal es que la imputacion estadistica no actua sobre el faltante bruto cuando hay una formula fisica disponible. Primero se reduce `pl_dens` mediante densidad fisica y `pl_orbsmax` mediante Kepler. Solo despues se imputan los residuos faltantes. La barra final debe caer a 0 % en todas las variables principales, lo cual certifica matriz completa.

15.2. 02_value_source_composition.pdf

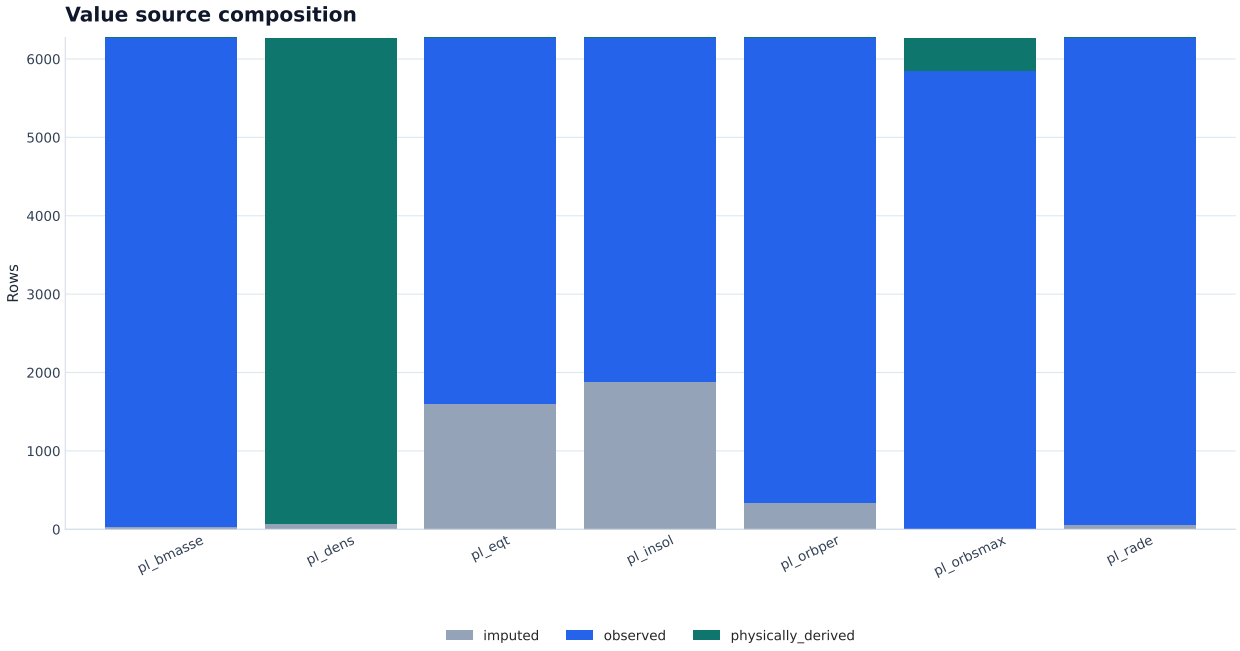

Figura 2: Composicion de fuentes: observado, derivado fisicamente e imputado.

Esta figura es la mas importante para no sobreinterpretar el dataset. Para cada variable descompone:

$$N_j = N_{j,\text{observed}} + N_{j,\text{physically derived}} + N_{j,\text{imputed}} + N_{j,\text{missing}}.$$

Debe verse que `pl_dens` esta dominada por physically_derived, no por observed. En cambio, `pl_insol` y `pl_eqt` conservan una fraccion imputada grande, lo que sugiere cautela al interpretar patrones termicos/orbitales dependientes de esas columnas.

15.3. 03_mapper_coverage.pdf

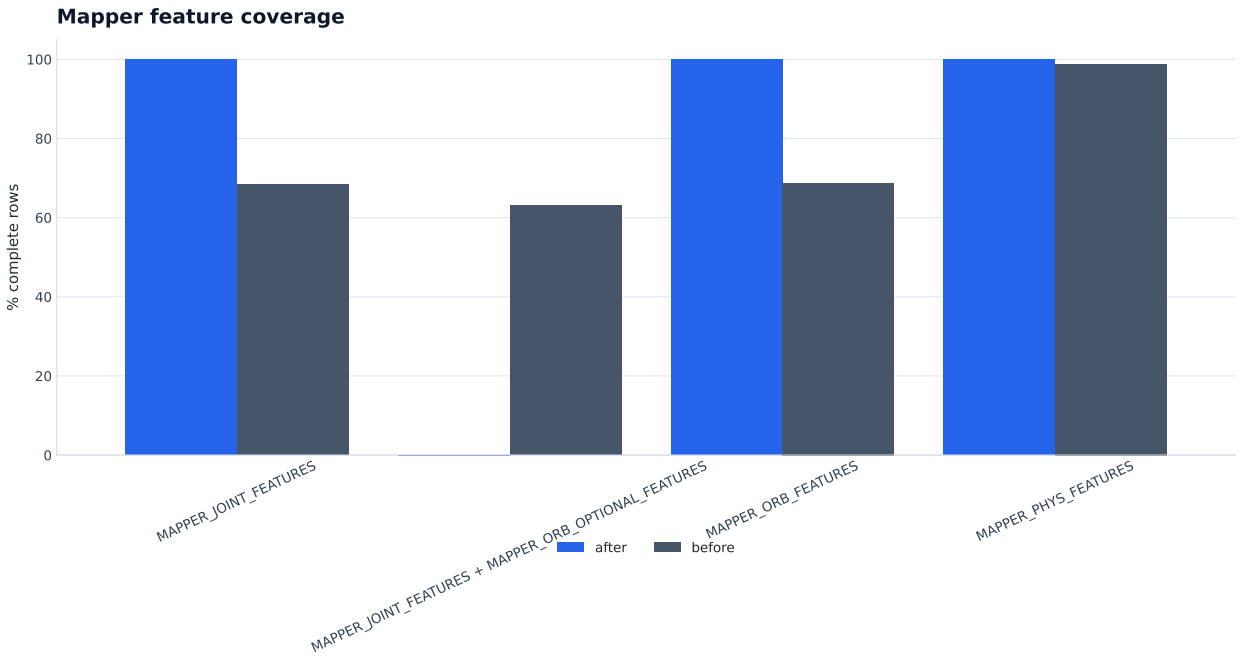

Figura 3: Cobertura de grupos Mapper antes/despues.

La figura evalua si los espacios usados por Mapper tienen filas completas. El salto critico es:

$$68{,}2608\,\% \longrightarrow 100\,\%$$

para $\mathcal{F}_{\text{joint}}$. Esto habilita Mapper sobre todos los planetas del catalogo, pero introduce dependencia del modelo de imputacion. Por eso el resultado topologico debe verse como sensibilidad bajo `iterative`, no como verdad unica del catalogo.

15.4. 04_masked_validation_mae_by_feature.pdf

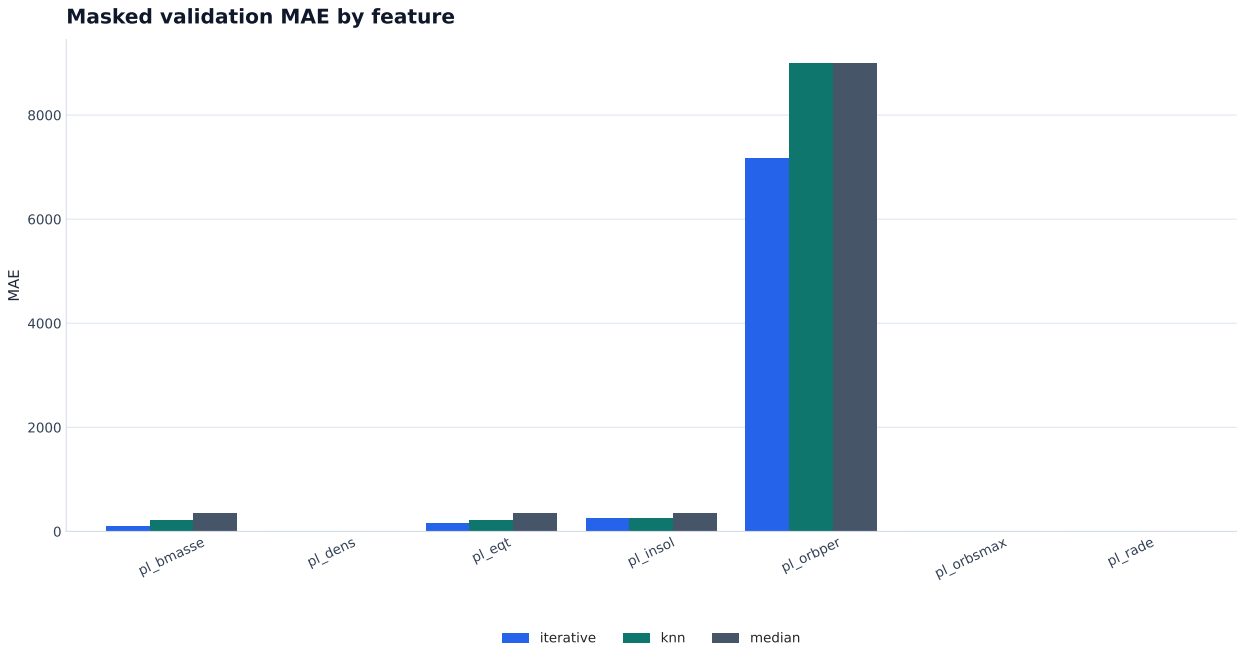

Figura 4: MAE por feature en validacion enmascarada.

El MAE esta en unidades fisicas de cada variable, por lo que no debe compararse directamente entre columnas con escalas distintas. La comparacion valida es entre metodos dentro de la misma feature. Si `iterative` queda sistematicamente por debajo de KNN y mediana, eso indica mejor reconstruccion puntual bajo la mascara aleatoria. Para variables de cola larga, el MAE puede estar dominado por outliers; por eso se complementa con errores logaritmicos y correlaciones.

15.5. 05_masked_validation_spearman_heatmap.pdf

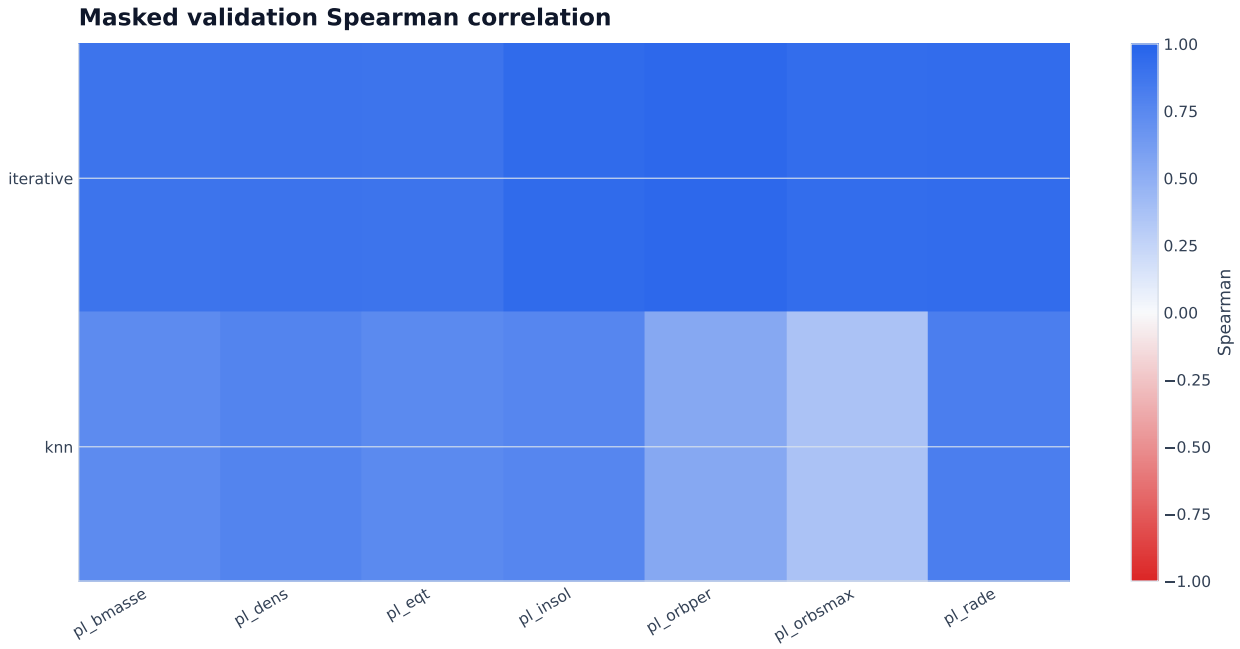

Figura 5: Correlacion de Spearman entre valores reales enmascarados y reconstruidos.

Spearman mide preservacion de orden:

$$\rho_s = \mathrm{corr}\left(\mathrm{rank}(x), \mathrm{rank}(\widehat{x})\right).$$

Una ρ_s alta indica que el imputador conserva jerarquias relativas aun si tiene errores absolutos grandes. Esto importa para Mapper porque la geometria de vecindad y las lentes pueden depender mas de ordenes relativos y rangos que de errores absolutos en unidades originales.

15.6. `06_method_comparison.pdf`

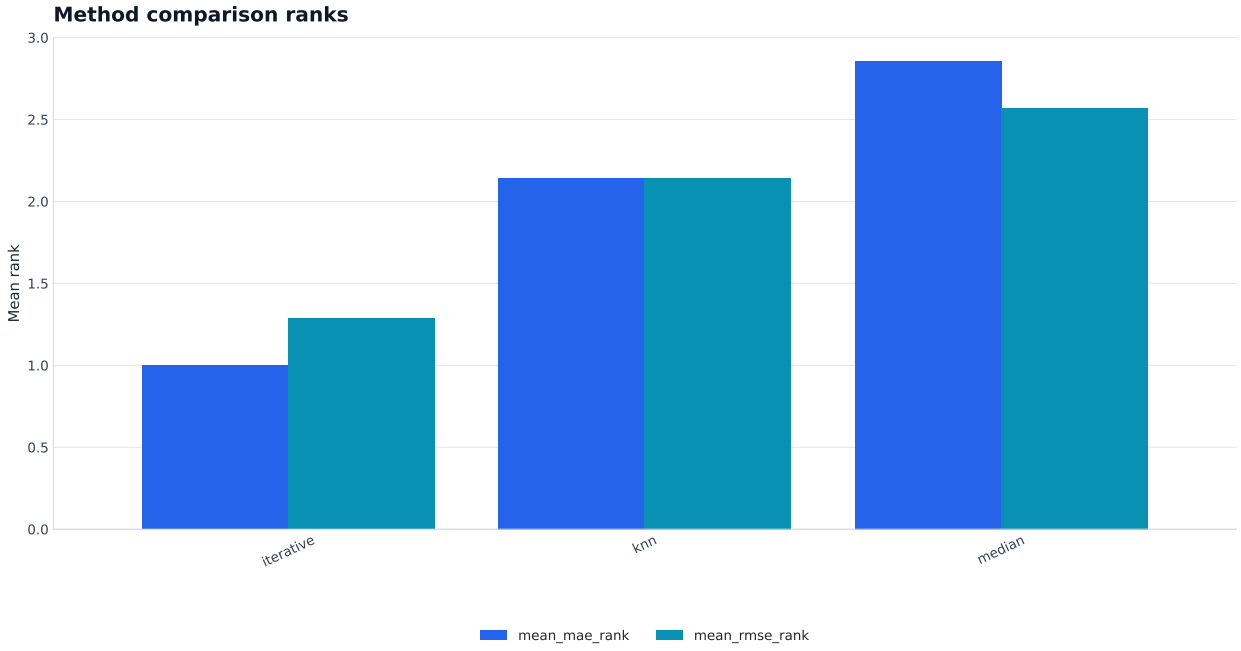

Figura 6: Comparacion agregada de metodos por ranks de error.

Esta figura justifica la decision de visualizar `iterative`. El criterio no es "`iterative` es verdadero", sino:

$$\bar{r}_{\mathrm{MAE}}(\text{iterative}) = 1{,}0 < \bar{r}_{\mathrm{MAE}}(\text{knn}) < \bar{r}_{\mathrm{MAE}}(\text{median}).$$

El metodo iterativo es, en promedio, el que mejor reconstruye valores ocultados. La interpretacion topologica sigue requiriendo comparar contra KNN y casos completos.

15.7. PDFs 07–13: distribuciones univariadas

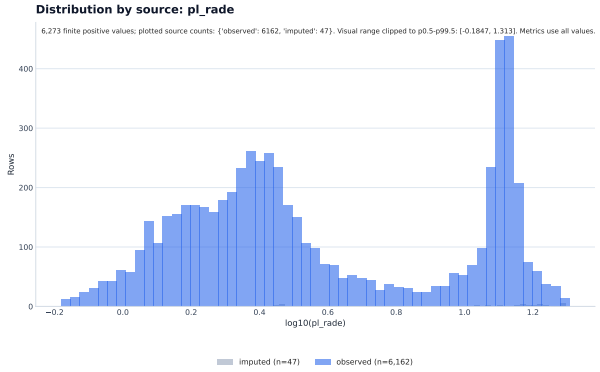

(a) `pl_rade`

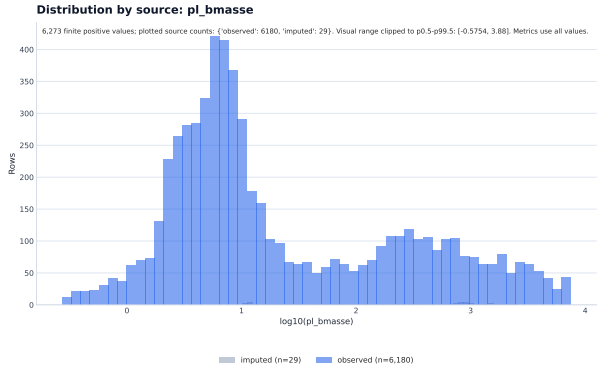

(b) `pl_bmasse`

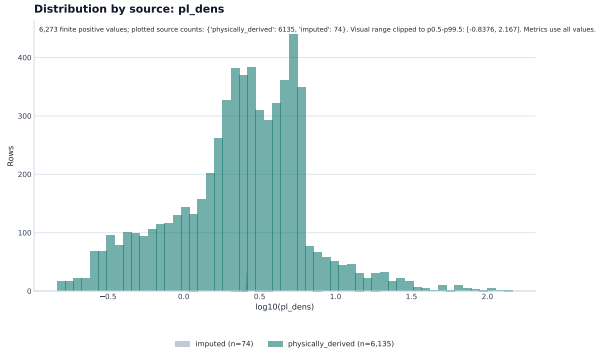

(c) `pl_dens`

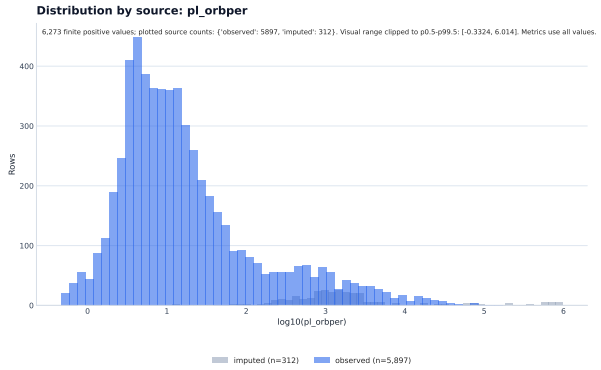

(d) `pl_orbper`

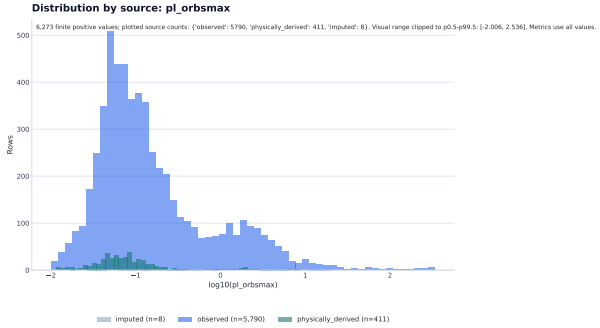

(e) `pl_orbsmax`

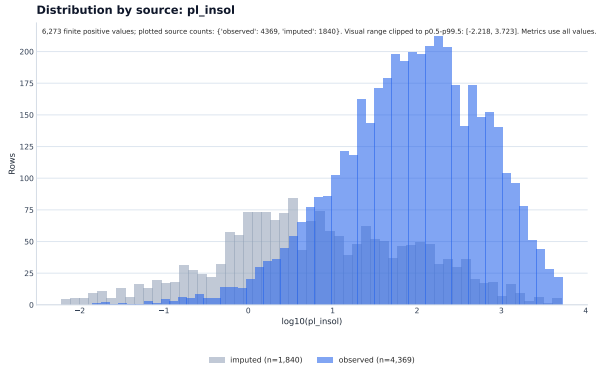

(f) `pl_insol`

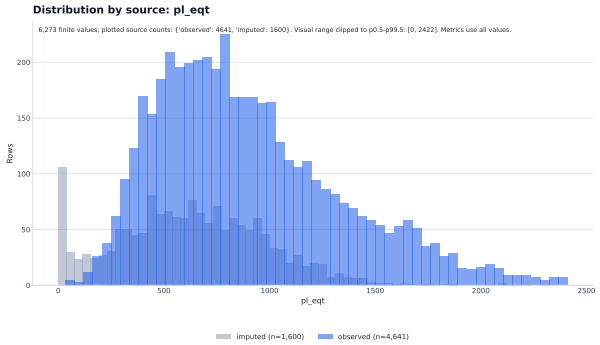

(g) `pl_eqt`

Figura 7: Distribution checks por variable. Las variables positivas de cola larga se leen en escala $\log_{10}$ cuando corresponde.

Estas figuras verifican que las distribuciones no quedaron vacias ni colapsadas por problemas de escala. Para

$$\texttt{pl_rade}, \texttt{pl_bmasse}, \texttt{pl_dens}, \texttt{pl_orbper}, \texttt{pl_orbsmax}, \texttt{pl_insol},$$

la lectura correcta usa $\log_{10}(\cdot)$ porque los rangos fisicos son muy asimetrico. La pregunta diagnostica no es si la distribucion imputada es identica a la observada, sino si:

$$\widehat{p}(x \mid \text{imputed})$$

cae en regiones plausibles de

$$\widehat{p}(x \mid \text{observed or physically derived}).$$

Si aparecieran masas, radios, densidades, periodos o insolaciones fuera de ordenes de magnitud razonables, habria que revisar clipping, transformaciones o el imputador.

`pl_rade`. Debe mostrar radios positivos y una distribucion dominada por observados, porque solo se imputaron 50 de 6273 filas. La imputacion aqui es de bajo peso relativo.

`pl_bmasse`. Debe leerse en log por la cola de masas. Solo 31 filas fueron imputadas, pero los errores absolutos pueden ser grandes porque masas planetarias tienen rango amplio.

`pl_dens`. La figura no representa observaciones originales de densidad; representa principalmente densidad derivada:

$$6199 \text{ derivadas}, \quad 74 \text{ imputadas}.$$

Su interpretacion es fisico-algebraica, no observacional directa.

`pl_orbper`. El periodo orbital requiere escala logaritmica por la presencia de colas muy largas. Los 339 imputados deben caer en continuidad con periodos observados.

`pl_orbsmax`. La mayor parte faltante se resolvio con Kepler, no con imputacion estadistica. Solo 8 filas quedaron imputadas despues de derivacion.

`pl_insol`. Tiene 1876 imputaciones, una proporcion grande. La distribucion debe inspeccionarse con cuidado porque la insolacion entra a relaciones fisicas con temperatura de equilibrio y distancia orbital.

`pl_eqt`. No usa log en el pipeline. Tiene 1600 imputaciones; por tanto cualquier patron termico posterior debe distinguir observados de imputados.

15.8. PDFs 14–17: scatter checks bivariados

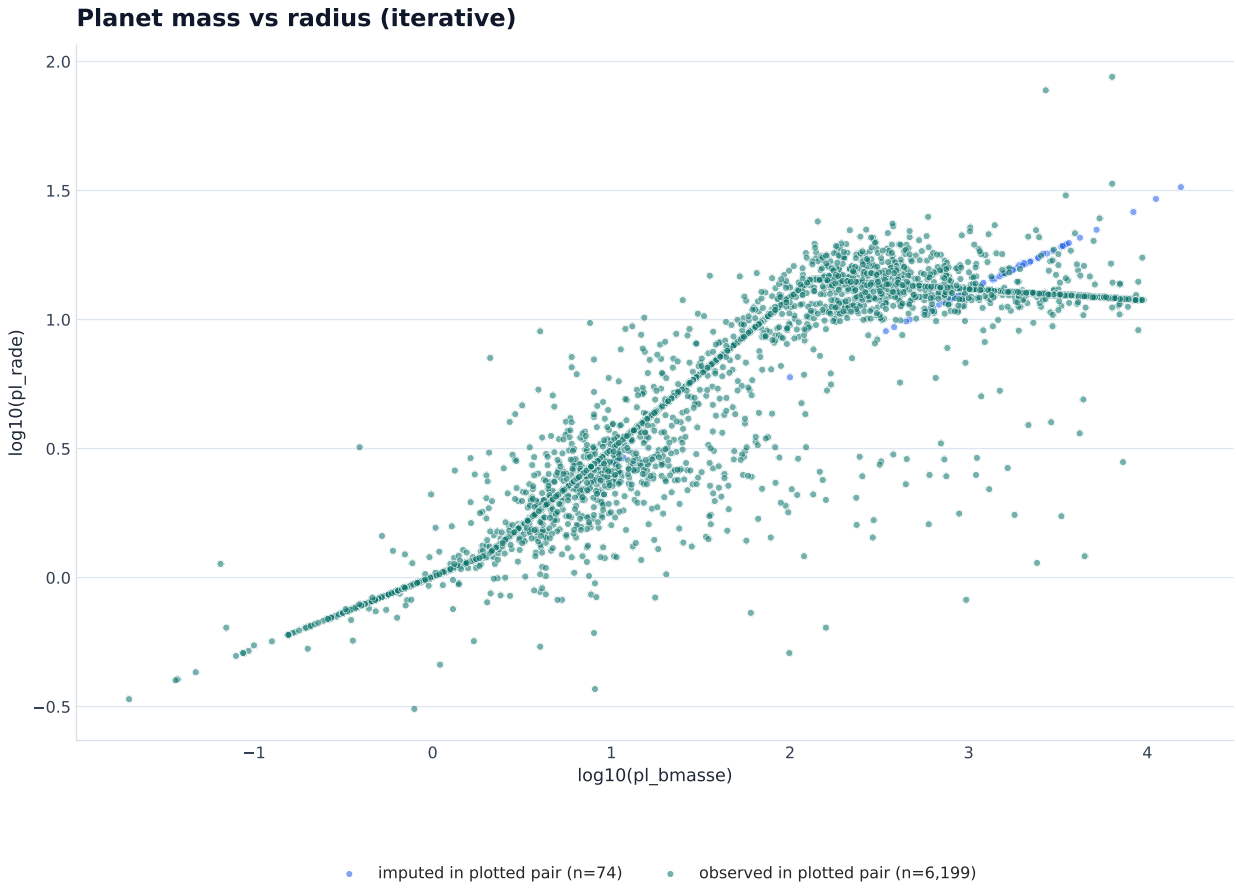

Figura 8: Masa vs radio, coloreado por estatus de imputacion, metodo `iterative`.

La relacion masa-radio es el control fisico basico. En escala log-log se espera una nube amplia, con transiciones entre planetas rocosos, sub-Neptunos, gigantes gaseosos y objetos masivos. La interpretacion de color es:

$$\text{status}(i) = \begin{cases} \text{observed pair}, & x_i, y_i \text{ observados}, \\ \text{physically derived in plotted pair}, & \exists \text{ coordenada derivada}, \\ \text{imputed in plotted pair}, & \exists \text{ coordenada imputada}. \end{cases}$$

Los puntos imputados no deben formar una nube artificial separada sin soporte observacional.

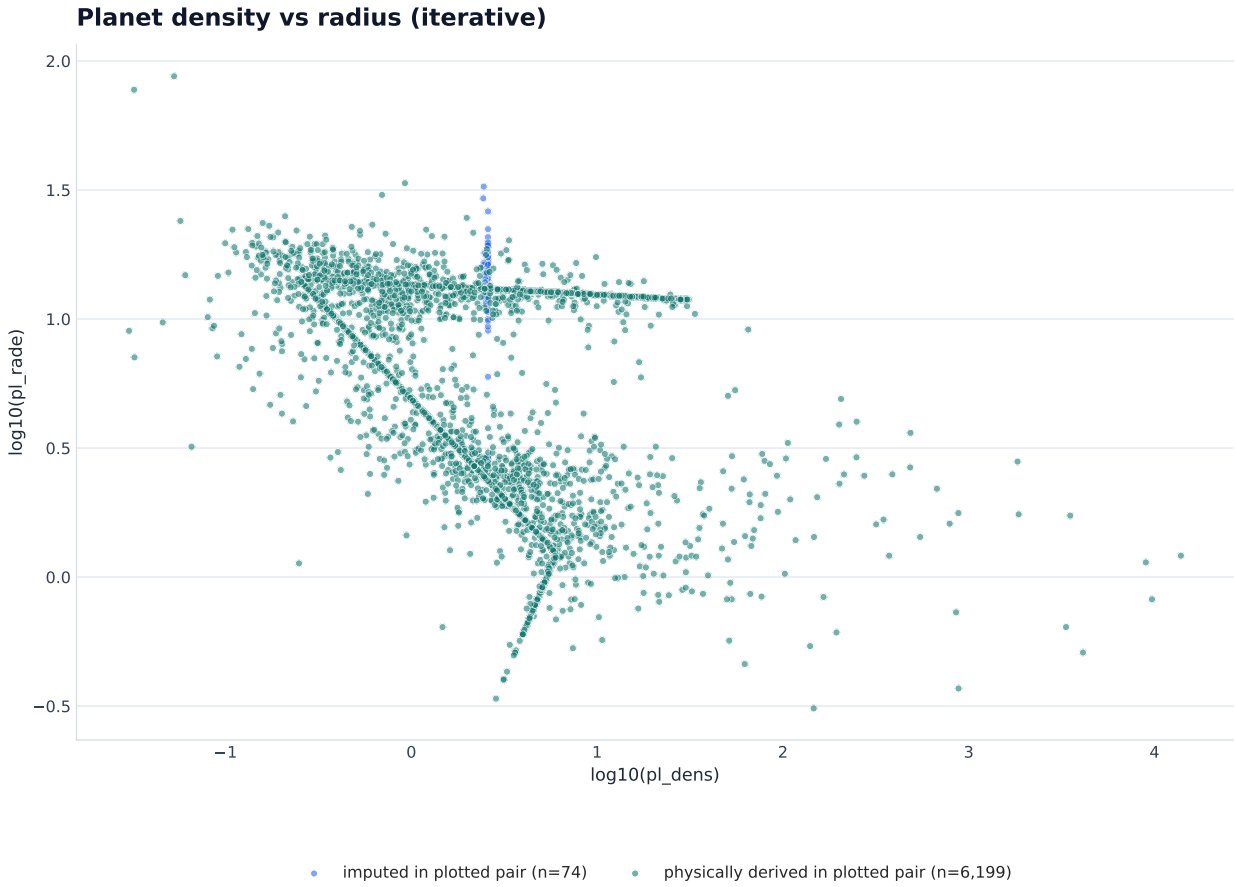

Figura 9: Densidad vs radio, coloreado por estatus de imputacion, metodo `iterative`.

Este scatter es particularmente delicado porque

$$\rho_p \propto \frac{M_p}{R_p^3}.$$

Al poner ρ_p contra R_p, parte de la estructura visual esta inducida por la formula misma. Si `pl_dens` fue derivada desde masa y radio, no es una coordenada independiente. Por eso el plot sirve para detectar coherencia fisica y outliers, no para afirmar una correlacion observacional independiente entre densidad y radio.

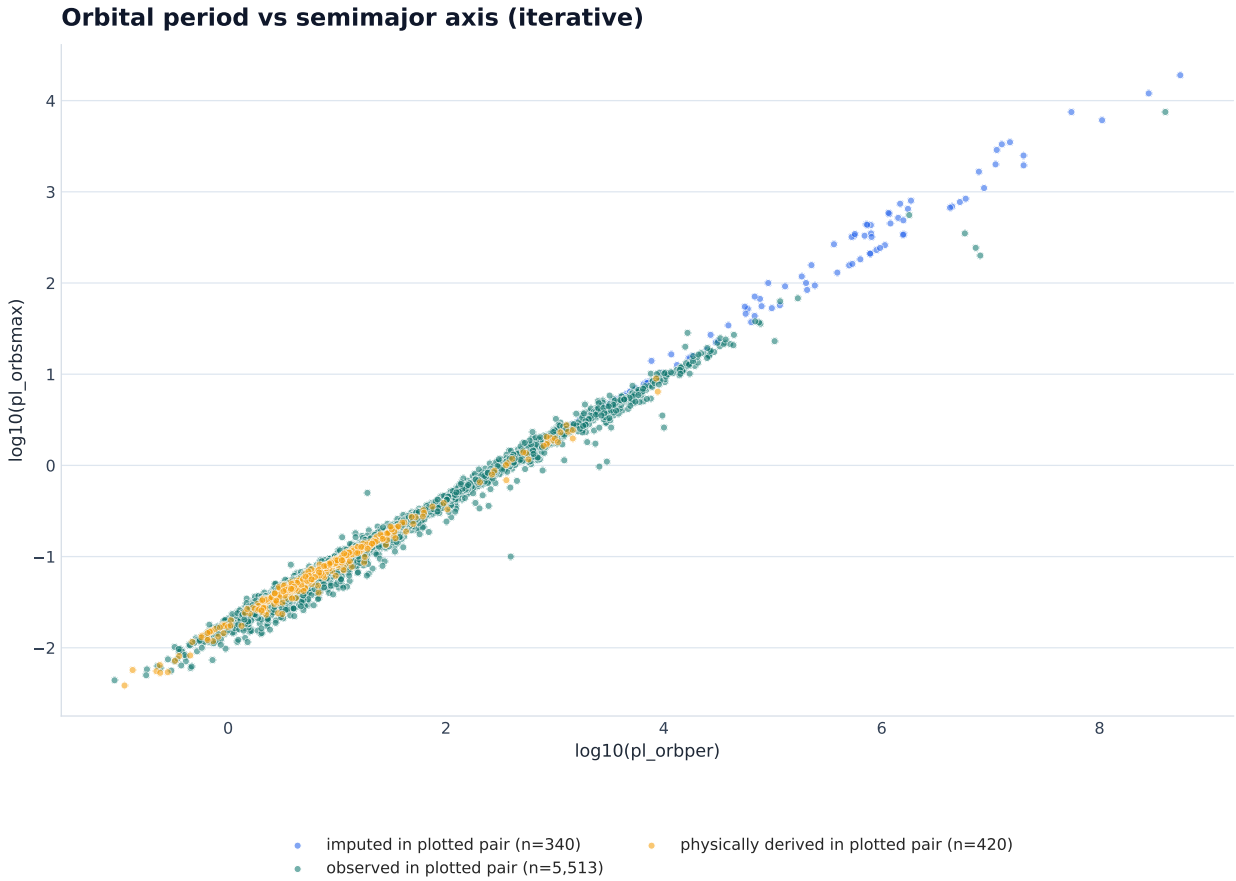

Figura 10: Periodo orbital vs semieje mayor, coloreado por estatus de imputacion, metodo `iterative`.

Este scatter debe reflejar la relacion kepleriana:

$$a \propto M_\star^{1/3} P^{2/3}.$$

En logaritmos:

$$\log a = \frac{1}{3}\log M_\star + \frac{2}{3}\log P - \frac{2}{3}\log 365{,}25.$$

Por tanto, una estructura aproximadamente monotona no es sorpresa; esta parcialmente inducida cuando `pl_orbsmax` fue derivado. El valor del plot es verificar que los pocos imputados estadisticamente no rompan esta relacion.

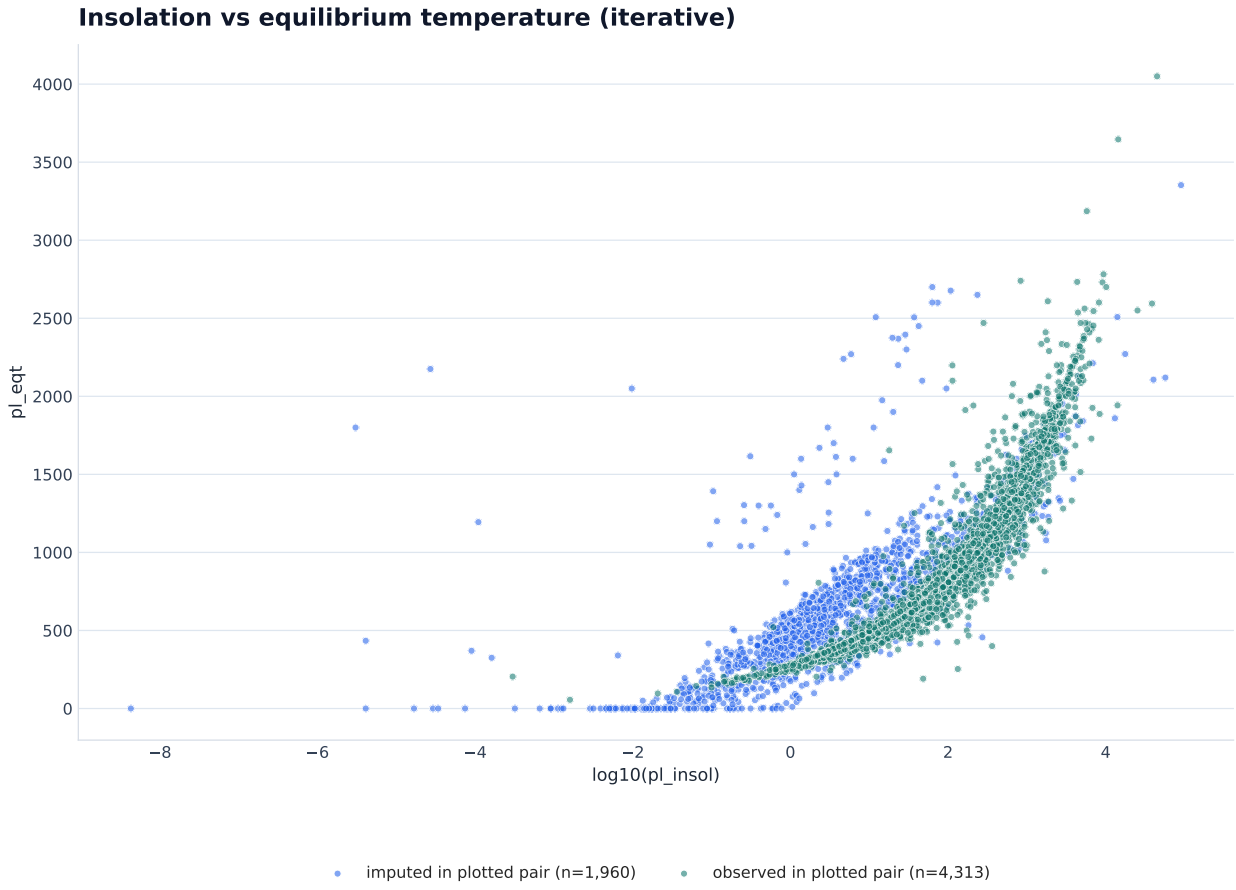

Figura 11: Insolacion vs temperatura de equilibrio, coloreado por estatus de imputacion, metodo `iterative`.

La temperatura de equilibrio e insolacion estan fisicamente relacionadas. De forma idealizada:

$$T_{\mathrm{eq}} \propto S^{1/4},$$

si se mantienen constantes albedo y redistribucion termica. En logaritmos:

$$\log T_{\mathrm{eq}} = C + \frac{1}{4} \log S.$$

Como `pl_insol` tiene 1876 imputaciones y `pl_eqt` tiene 1600, este scatter es un diagnostico de coherencia termica del imputador `iterative`. Si los puntos imputados se alinean razonablemente con la nube principal, el metodo preserva una relacion fisica esperada; si se separan, habria sesgo en variables termicas.

16. Lectura de tablas exportadas

Las tablas principales exportadas en CSV y JSON son:

- `imputation_method_comparison`.
- `imputation_validation_metrics`.
- `imputation_value_source_composition`.

- `imputation_missingness_summary`.
- `mapper_coverage_summary`.

16.1. `imputation_method_comparison`

Esta tabla no debe interpretarse como prueba ontologica de que un metodo es "correcto". Es una comparacion empirica bajo mascara aleatoria:

$$m^\star = \arg\min_m \left[\bar{r}_{\mathrm{MAE}}(m)\right].$$

El resultado favorece `iterative` por error promedio, pero no elimina la necesidad de sensibilidad topologica.

16.2. `imputation_validation_metrics`

La columna mas importante conceptualmente es `validation_basis`. En particular:

$$\texttt{pl_dens}: \quad \texttt{validation_basis} = \text{physically_derived}.$$

Esto significa que al ocultar y reconstruir `pl_dens`, la verdad comparativa era la densidad calculada por formula, no una medicion original.

16.3. `imputation_value_source_composition`

Esta tabla es la auditoria de procedencia. Debe acompanar cualquier analisis posterior porque permite filtrar o ponderar:

$$\widehat{X}_{\mathrm{obs}}, \quad \widehat{X}_{\mathrm{phys}}, \quad \widehat{X}_{\mathrm{imp}}.$$

Para un analisis conservador se pueden comparar resultados usando:

$$\{\text{observed}\} \quad \text{vs.} \quad \{\text{observed}, \text{physically_derived}\} \quad \text{vs.} \quad \{\text{observed}, \text{physically_derived}, \text{imputed}\}.$$

16.4. `imputation_missingness_summary`

Esta tabla documenta en que etapa se resolvio cada hueco. Es crucial porque `pl_dens` parece inicialmente inutilizable al estar 100 % faltante, pero se vuelve casi completa despues de derivacion fisica.

16.5. `mapper_coverage_summary`

Esta tabla conecta imputacion con TDA. El salto de cobertura del espacio conjunto:

$$4282 \to 6273$$

indica cuantas filas adicionales entran al grafo Mapper gracias al pipeline. Esa ganancia de cobertura es util, pero cambia la distribucion geometrica del espacio analizado.

17. Implicaciones para Mapper/TDA

Mapper no opera sobre los datos crudos directamente, sino sobre una nube

$$\mathcal{X} = \{\widehat{\mathbf{x}}_1, \ldots, \widehat{\mathbf{x}}_n\} \subset \mathbb{R}^p$$

despues de transformacion, escalado e imputacion. Una lente

$$f : \mathcal{X} \to \mathbb{R}^d$$

define una cubierta $\mathcal{U}$ del espacio de lentes; luego se agrupan puntos en preimagenes $f^{-1}(U_\alpha)$, y se construye un grafo por interseccion de clusters. Por tanto, pequenas perturbaciones en $\widehat{\mathbf{x}}_i$ pueden alterar:

$$f(\widehat{\mathbf{x}}_i), \quad \text{cluster}(\widehat{\mathbf{x}}_i), \quad E(G_{\text{Mapper}}).$$

El pipeline mejora cobertura:

$$\text{coverage}_{\text{joint}} = 100\,\%.$$

Pero la estabilidad topologica debe evaluarse con comparaciones:

$$G_{\text{complete}}, \quad G_{\text{median}}, \quad G_{\text{knn}}, \quad G_{\text{iterative}}, \quad G_{\text{bootstrap}}, \quad G_{\text{params}}.$$

Una conclusion topologica fuerte deberia persistir bajo varias de estas condiciones.

18. Criterios de aceptacion cumplidos

1. El HTML final contiene `METODO VISUALIZADO = iterative`.
2. Los plots dependientes del metodo usan `iterative`.
3. Los histogramas/distribuciones no estan vacios por problemas de escala.
4. Los scatter finales 14–17 usan `iterative`.
5. Hay 17 PDFs individuales en `reports/imputation/outputs/figures_pdf` y todos tienen tamano mayor que cero.
6. Las tablas principales existen como CSV y JSON en `reports/imputation/outputs/tables`.
7. El reporte distingue observados, derivados fisicamente e imputados.
8. `pl_dens` se describe como derivada desde masa y radio cuando aplica.
9. No quedan NA, $+\infty$ ni $-\infty$ en las siete features principales para el metodo `iterative`.
10. La estructura del repositorio se mantuvo; no se reescribio el pipeline.

19. Advertencias no bloqueantes

La suite de pruebas paso:

$$18 \text{ passed}, \qquad 1 \text{ warning}.$$

El warning observado corresponde a carga simultanea de bibliotecas OpenMP `libiomp` y `libomp` reportada por `threadpoolctl`. Esto es una advertencia del stack numerico local, no un fallo del pipeline de imputacion.

20. Conclusiones

El pipeline final produce una matriz completa para las siete variables Mapper principales, con trazabilidad explicita de procedencia. La decision de visualizar `iterative` esta respaldada por validacion enmascarada y rank promedio de error. Sin embargo, el documento conserva la distincion epistemica central:

$$\text{observado} \neq \text{derivado fisicamente} \neq \text{imputado}.$$

En particular,

$$\texttt{pl_dens} = 5{,}514\,\frac{\texttt{pl_bmasse}}{\texttt{pl_rade}^3}$$

para 6199 filas, y solo 74 densidades finales provienen de imputacion estadistica bajo `iterative`. Por tanto, cualquier interpretacion fisica o topologica posterior debe reportar el metodo, las fuentes de valor y la comparacion contra alternativas.

A. Rutas de artefactos

- HTML final: `reports/imputation/imputation_report.html`.
- Figuras PDF: `reports/imputation/outputs/figures_pdf/`.
- Tablas CSV/JSON: `reports/imputation/outputs/tables/`.
- CSV imputado visualizado: `reports/imputation/PSCompPars_imputed_iterative.csv`.
- Features Mapper visualizadas: `reports/imputation/mapper_features_imputed_iterative.csv`.

B. Inventario de PDFs

PDF	Bytes
`01_missingness_before_after.pdf`	20745
`02_value_source_composition.pdf`	19610
`03_mapper_coverage.pdf`	20873
`04_masked_validation_mae_by_feature.pdf`	19213
`05_masked_validation_spearman_heatmap.pdf`	21825
`06_method_comparison.pdf`	16144
`07_distribution_pl_rade.pdf`	27262
`08_distribution_pl_bmasse.pdf`	27034
`09_distribution_pl_dens.pdf`	26821
`10_distribution_pl_orbper.pdf`	26234
`11_distribution_pl_orbsmax.pdf`	29210
`12_distribution_pl_insol.pdf`	26821
`13_distribution_pl_eqt.pdf`	26521
`14_scatter_mass_radius.pdf`	116627
`15_scatter_density_radius.pdf`	116363
`16_scatter_orbper_orbsmax.pdf`	119954
`17_scatter_insol_eqt.pdf`	111064